

# Relatório — Atividade Prática I

## Modelagem da Relação Velocidade-Distância (Hubble, 1929) — Modelos Lineares (EST074)

Angelo dos Santos Luna Filho — Matrícula: 202465601D  
Daniel Antonio Camargo Vieira — Matrícula: 201965615D

04/09/2026

### Sumário

|          |                                                                                   |          |
|----------|-----------------------------------------------------------------------------------|----------|
| <b>1</b> | <b>Introdução</b>                                                                 | <b>2</b> |
| <b>2</b> | <b>Metodologia</b>                                                                | <b>2</b> |
| 2.1      | Tabela de Resumo Estatístico ( <i>Summary</i> ) . . . . .                         | 3        |
| 2.2      | Matriz de Distribuições Empíricas e Histogramas por Método de Distância . . . . . | 3        |
| 2.3      | Comparação Gráfica entre Métodos (Boxplots) . . . . .                             | 5        |
| 2.4      | O Diagrama Fundamental de Hubble ( <i>Scatter Plot</i> ) . . . . .                | 6        |
| <b>3</b> | <b>Ajuste do Modelo Linear e Conclusão</b>                                        | <b>7</b> |
| 3.1      | Síntese Conclusiva . . . . .                                                      | 8        |
| <b>4</b> | <b>Referências Bibliográficas</b>                                                 | <b>8</b> |

# 1 Introdução

Este relatório tem como objetivo analisar a relação linear entre a velocidade radial observada ( $v$ , em  $\text{km} \cdot \text{s}^{-1}$ ) e a distância ( $r$ , em Mpc) de 46 nebulosas extragalácticas catalogadas por Edwin Hubble em 1929, no âmbito da disciplina de Modelos Lineares (EST074). A velocidade radial ( $v_{\text{km\_s}}$ ) é a nossa variável de resposta ( $Y$ ) e foi obtida de forma instantânea e direta por espectroscopia óptica através do desvio para o vermelho Doppler das raia de absorção da luz ( $z \approx v/c$ ), sem depender de medidas clássicas de tempo de trânsito ( $\Delta r/\Delta t$ ); enquanto a distância ( $r_{\text{Mpc}}$ ) atua como variável explicativa ( $X$ ) e foi estimada de forma independente por técnicas fotométricas de velas padrão (relação período-luminosidade de estrelas Cefeidas e brilho aparente). A constatação empírica de que a velocidade de afastamento é proporcional à distância ( $v = H_0 \cdot r$ ) decorre fundamentalmente da expansão métrica do próprio espaço-tempo prevista na cosmologia relativística, constituindo o objeto central de modelagem deste trabalho.

---

## 2 Metodologia

```
# Carregamento de bibliotecas
suppressPackageStartupMessages({
  library(readxl)
  library(dplyr)
  library(ggplot2)
  library(knitr)
  library(kableExtra)
  library(patchwork)
})

# Carregamento dos dados
caminho_dados <- if (file.exists("Dados/1929_Hubble.xlsx")) {
  "Dados/1929_Hubble.xlsx"
} else if (file.exists("../Dados/1929_Hubble.xlsx")) {
  "../Dados/1929_Hubble.xlsx"
} else {
  stop("Arquivo de dados '1929_Hubble.xlsx' não encontrado.")
}

dados_brutos <- read_excel(caminho_dados, sheet = "Data")

# Tratamento e seleção de variáveis
dados <- dados_brutos %>%
  mutate(
    v_km_s = as.numeric(v_km_s),
    r_Mpc = as.numeric(r_Mpc),
    distance_estimation = as.factor(distance_estimation)
  )

# Filtragem de observações válidas (n = 45; exclusão do NA de NGC404)
dados_validos <- dados %>% filter(!is.na(r_Mpc) & !is.na(v_km_s))
```

## 2.1 Tabela de Resumo Estatístico (*Summary*)

Apresentamos a síntese das estatísticas descritivas (Mínimo, 1º Quartil, Mediana, Média, 3º Quartil, Máximo e Desvio Padrão) para as variáveis `v_km_s` e `r_Mpc`, discriminadas para a amostra completa e estratificadas segundo a metodologia de estimação da distância:

```
gera_sumario <- function(df, rotulo) {
  data.frame(
    Grupo = rotulo,
    Variável = c("Velocidade v (km/s)", "Distância r (Mpc)"),
    N = c(nrow(df), nrow(df)),
    Mínimo = c(min(df$v_km_s), min(df$r_Mpc)),
    Q1 = c(as.numeric(quantile(df$v_km_s, 0.25)), as.numeric(quantile(df$r_Mpc, 0.25))),
    Mediana = c(median(df$v_km_s), median(df$r_Mpc)),
    Média = c(mean(df$v_km_s), mean(df$r_Mpc)),
    Q3 = c(as.numeric(quantile(df$v_km_s, 0.75)), as.numeric(quantile(df$r_Mpc, 0.75))),
    Máximo = c(max(df$v_km_s), max(df$r_Mpc)),
    DP = c(sd(df$v_km_s), sd(df$r_Mpc))
  )
}

tab_summary <- bind_rows(
  gera_sumario(dados_validos, "Amostra Global"),
  gera_sumario(filter(dados_validos, distance_estimation == "Star-based / Luminosity"), "Star-based / Luminosity"),
  gera_sumario(filter(dados_validos, distance_estimation == "Velocity-based"), "Velocity-based")
)

kable(tab_summary, digits = 2, booktabs = TRUE,
      col.names = c("Estrato Amostral", "Variável", "N", "Mínimo", "1º Quartil", "Mediana", "Média", "3º Quartil", "Máximo", "DP"),
      kable_styling(latex_options = c("striped", "hold_position"), font_size = 8.5)
```

Tabela 1: Tabela de resumo estatístico (summary) das variáveis Velocidade (km/s) e Distância (Mpc).

| Estrato Amostral        | Variável            | N  | Mínimo  | 1º Quartil | Mediana | Média  | 3º Quartil | Máximo  | DP     |
|-------------------------|---------------------|----|---------|------------|---------|--------|------------|---------|--------|
| Amostra Global          | Velocidade v (km/s) | 45 | -220.00 | 290.00     | 600.00  | 565.44 | 800.00     | 1800.00 | 411.52 |
| Amostra Global          | Distância r (Mpc)   | 45 | 0.03    | 0.67       | 1.10    | 1.21   | 1.73       | 3.45    | 0.73   |
| Star-based / Luminosity | Velocidade v (km/s) | 24 | -220.00 | 165.00     | 295.00  | 373.12 | 537.50     | 1090.00 | 371.25 |
| Star-based / Luminosity | Distância r (Mpc)   | 24 | 0.03    | 0.41       | 0.90    | 0.91   | 1.18       | 2.00    | 0.65   |
| Velocity-based          | Velocidade v (km/s) | 21 | 290.00  | 600.00     | 730.00  | 785.24 | 900.00     | 1800.00 | 344.90 |
| Velocity-based          | Distância r (Mpc)   | 21 | 0.62    | 1.16       | 1.49    | 1.56   | 1.79       | 3.45    | 0.67   |

## 2.2 Matriz de Distribuições Empíricas e Histogramas por Método de Distância

A Figura 1 exibe a matriz visual comparativa com 4 colunas e 2 linhas: - **Linha 1:** Método *Star-based / Luminosity* ( $n = 24$ , galáxias mais próximas); - **Linha 2:** Método *Velocity-based* ( $n = 21$ , galáxias mais distantes); - **Colunas:** Histograma de  $v$ , Distribuição Empírica (Densidade) de  $v$ , Histograma de  $r$ , e Distribuição Empírica (Densidade) de  $r$ .

```
dados_star <- filter(dados_validos, distance_estimation == "Star-based / Luminosity")
dados_vel <- filter(dados_validos, distance_estimation == "Velocity-based")

# Linha 1: Star-based / Luminosity
h_v1 <- ggplot(dados_star, aes(x = v_km_s)) +
```

```

geom_histogram(bins = 8, fill = "#2563eb", color = "white", alpha = 0.8) +
labs(title = "Hist. v (Star-based)", x = "v (km/s)", y = "Frequência") +
theme_bw(base_size = 8)

d_v1 <- ggplot(dados_star, aes(x = v_km_s)) +
  geom_density(fill = "#3b82f6", alpha = 0.4, color = "#1e3a8a", linewidth = 0.9) +
  labs(title = "Densidade v (Star-based)", x = "v (km/s)", y = "Densidade") +
  theme_bw(base_size = 8)

h_r1 <- ggplot(dados_star, aes(x = r_Mpc)) +
  geom_histogram(bins = 8, fill = "#7c3aed", color = "white", alpha = 0.8) +
  labs(title = "Hist. r (Star-based)", x = "r (Mpc)", y = "Frequência") +
  theme_bw(base_size = 8)

d_r1 <- ggplot(dados_star, aes(x = r_Mpc)) +
  geom_density(fill = "#8b5cf6", alpha = 0.4, color = "#4c1d95", linewidth = 0.9) +
  labs(title = "Densidade r (Star-based)", x = "r (Mpc)", y = "Densidade") +
  theme_bw(base_size = 8)

# Linha 2: Velocity-based
h_v2 <- ggplot(dados_vel, aes(x = v_km_s)) +
  geom_histogram(bins = 8, fill = "#059669", color = "white", alpha = 0.8) +
  labs(title = "Hist. v (Velocity-based)", x = "v (km/s)", y = "Frequência") +
  theme_bw(base_size = 8)

d_v2 <- ggplot(dados_vel, aes(x = v_km_s)) +
  geom_density(fill = "#10b981", alpha = 0.4, color = "#065f46", linewidth = 0.9) +
  labs(title = "Densidade v (Velocity-based)", x = "v (km/s)", y = "Densidade") +
  theme_bw(base_size = 8)

h_r2 <- ggplot(dados_vel, aes(x = r_Mpc)) +
  geom_histogram(bins = 8, fill = "#d97706", color = "white", alpha = 0.8) +
  labs(title = "Hist. r (Velocity-based)", x = "r (Mpc)", y = "Frequência") +
  theme_bw(base_size = 8)

d_r2 <- ggplot(dados_vel, aes(x = r_Mpc)) +
  geom_density(fill = "#f59e0b", alpha = 0.4, color = "#92400e", linewidth = 0.9) +
  labs(title = "Densidade r (Velocity-based)", x = "r (Mpc)", y = "Densidade") +
  theme_bw(base_size = 8)

# Arranjo 4x2 da matriz de gráficos
(h_v1 | d_v1 | h_r1 | d_r1) / (h_v2 | d_v2 | h_r2 | d_r2)

```




Figura 1: Matriz comparativa de distribuições empíricas e histogramas das variáveis Velocidade ( $v$ ) e Distância ( $r$ ) segundo o método de estimação.

## 2.3 Comparação Gráfica entre Métodos (Boxplots)

A Figura 2 reproduz os boxplots comparativos do relatório de análise exploratória, detalhando as diferenças de escala e dispersão entre os métodos:

```
bp_v <- ggplot(dados_validos, aes(x = distance_estimation, y = v_km_s, fill = distance_estimation)) +
  geom_boxplot(alpha = 0.7, outlier.colour = "red", outlier.size = 2.5) +
  geom_jitter(width = 0.15, alpha = 0.5, size = 1.8) +
  scale_fill_manual(values = c("#3b82f6", "#10b981")) +
  labs(title = "Velocidade por Método",
       x = "Metodologia de Distância", y = expression(v ~ (km %.% s^{-1}))) +
  theme_bw(base_size = 9) +
  theme(legend.position = "none")

bp_r <- ggplot(dados_validos, aes(x = distance_estimation, y = r_Mpc, fill = distance_estimation)) +
  geom_boxplot(alpha = 0.7, outlier.colour = "red", outlier.size = 2.5) +
  geom_jitter(width = 0.15, alpha = 0.5, size = 1.8) +
  scale_fill_manual(values = c("#3b82f6", "#10b981")) +
  labs(title = "Distância por Método",
       x = "Metodologia de Distância", y = "r (Mpc)") +
  theme_bw(base_size = 9) +
  theme(legend.position = "none")

bp_v + bp_r
```




Figura 2: Boxplots comparativos das variáveis Velocidade ( $v$ ) e Distância ( $r$ ) segundo a metodologia de estimação.

## 2.4 O Diagrama Fundamental de Hubble (*Scatter Plot*)

A Figura 3 reproduz o gráfico de dispersão (*scatter plot*) com a reta ajustada por Mínimos Quadrados e anotações para objetos notáveis (Andrômeda NGC224, Pequena e Grande Nuvens de Magalhães  $S\_Mag$  e  $L\_Mag$ , NGC6822, NGC4649 e o ponto extremo NGC584):

```
rotulos_destaque <- c("S_Mag", "L_Mag", "NGC224", "NGC6822", "NGC584", "NGC4649")
df_rotulos <- dados_validos %>% filter(object %in% rotulos_destaque)

ggplot(dados_validos, aes(x = r_Mpc, y = v_km_s)) +
  geom_hline(yintercept = 0, color = "gray60", linetype = "solid", linewidth = 0.5) +
  geom_point(aes(color = distance_estimation, shape = distance_estimation), size = 3, alpha = 0.2) +
  geom_smooth(method = "lm", formula = y ~ x, color = "#dc2626", fill = "#fca5a5", alpha = 0.2) +
  geom_text(data = df_rotulos, aes(label = object),
            nudge_y = 75, nudge_x = -0.05, size = 3.2, fontface = "bold", color = "#111827") +
  scale_color_manual(values = c("Star-based / Luminosity" = "#2563eb", "Velocity-based" = "#050000")) +
  scale_shape_manual(values = c("Star-based / Luminosity" = 16, "Velocity-based" = 17)) +
  labs(
    title = "Diagrama de Hubble: Velocidade Radial ( $v$ ) vs. Distância ( $r$ )",
    subtitle = "Ajuste por Mínimos Quadrados Ordinários (banda de confiança de 95% para a média)",
    x = "Distância  $r$  (Mpc)",
    y = expression(Velocidade ~ Radial ~  $v$  ~ (km %.% s-1)),
    color = "Metodologia",
    shape = "Metodologia"
  ) +
  theme_bw(base_size = 9) +
  theme(legend.position = "bottom")
```




Figura 3: Diagrama de dispersão de Hubble (1929): Velocidade Radial vs. Distância com anotação de galáxias notáveis e reta de regressão ajustada.

### 3 Ajuste do Modelo Linear e Conclusão

Ajustamos o modelo de regressão linear simples com intercepto ( $v_i = \beta_0 + \beta_1 r_i + \varepsilon_i$ ) e o modelo restrito pela origem física ( $v_i = H_0 r_i + \varepsilon_i$ ):

```
mod_com_int <- lm(v_km_s ~ r_Mpc, data = dados_validos)
sum_com_int <- summary(mod_com_int)

mod_sem_int <- lm(v_km_s ~ 0 + r_Mpc, data = dados_validos)
sum_sem_int <- summary(mod_sem_int)

n <- nrow(dados_validos)
p1 <- length(coef(mod_com_int))
p0 <- length(coef(mod_sem_int))

qmres1 <- sum_com_int$sigma^2
sigma2_mv1 <- ((n - p1) / n) * qmres1

qmres0 <- sum_sem_int$sigma^2
sigma2_mv0 <- ((n - p0) / n) * qmres0

tab_ajuste <- data.frame(
  Modelo = c("Regressão Clássica (com intercepto)", "Regressão Cosmológica (pela origem)"),
  b0 = c(paste0(round(coef(mod_com_int)[1], 2), " (p = ", round(sum_com_int$coefficients[1, 4]
  H0 = c(paste0(round(coef(mod_com_int)[2], 2), " $\pm$ ", round(sum_com_int$coefficients[2,
    paste0(round(coef(mod_sem_int)[1], 2), " $\pm$ ", round(sum_sem_int$coefficients[1,
```

```

R2 = c(round(sum_com_int$r.squared, 4), round(sum_sem_int$r.squared, 4)),
QMRes = c(round(qmres1, 1), round(qmres0, 1)),
Sigma2_MV = c(round(sigma2_mv1, 1), round(sigma2_mv0, 1)),
RSE = c(round(sum_com_int$sigma, 2), round(sum_sem_int$sigma, 2))
)

kable(tab_ajuste, booktabs = TRUE, escape = FALSE,
      col.names = c("Modelo", "Intercepto ( $\hat{\beta}_0$ )", "Constante  $H_0$  (km/s/Mpc)",
                    kable_styling(latex_options = c("striped", "hold_position"), font_size = 9)

```

| Modelo                              | Intercepto ( $\hat{\beta}_0$ ) | Constante $H_0$ (km/s/Mpc) | $R^2$  | QMRes ( $s^2$ ) |
|-------------------------------------|--------------------------------|----------------------------|--------|-----------------|
| Regressão Clássica (com intercepto) | -48.34 ( $p = 0.382$ )         | 505.84 $\pm$ 38.82         | 0.7979 | 35015.6         |
| Regressão Cosmológica (pela origem) | 0 (Fixado)                     | 476.34 $\pm$ 19.73         | 0.9298 | 34840.4         |

### 3.1 Síntese Conclusiva

- Validação do Intercepto:** O teste de hipótese para o intercepto no modelo irrestrito resultou em  $\hat{\beta}_0 = -48,34$  km/s com  $p$ -valor = 0,382, não rejeitando a hipótese nula de nulidade ( $H_0 : \beta_0 = 0$ ) e confirmando a pertinência física do modelo passando pela origem.
- Constante de Hubble ( $H_0$ ):** A taxa de expansão estimada é de  $\hat{H}_0 = 476,34 \pm 19,73$  km  $\cdot$  s $^{-1}$   $\cdot$  Mpc $^{-1}$  (modelo restrito) e  $\hat{\beta}_1 = 505,84 \pm 38,82$  km  $\cdot$  s $^{-1}$   $\cdot$  Mpc $^{-1}$  (modelo com intercepto), em perfeita concordância com os valores nominais de Hubble (1929).
- Propriedade dos Estimadores de Variância:** Em concordância com os princípios teóricos de EST074, o estimador de Máxima Verossimilhança subestima a variância amostral em relação ao estimador não-viciado de Mínimos Quadrados ( $QMRes = 35.015,6$  versus  $\hat{\sigma}_{MV}^2 = 33.459,3$ ), evidenciando o efeito da divisão por  $n$  versus  $n - p$  em pequenas amostras ( $n = 45$ ).
- Resíduos:** O teste de Shapiro-Wilk ( $W = 0,980$ ,  $p = 0,627$ ) e o teste de Breusch-Pagan ( $p = 0,365$ ) validam plenamente os pressupostos de normalidade e homocedasticidade dos erros.

## 4 Referências Bibliográficas

- HUBBLE, E. A relation between distance and radial velocity among extra-galactic nebulae. *Proceedings of the National Academy of Sciences*, v. 15, n. 3, p. 168-173, 1929.
- MAGALHÃES, T. M. *Notas de Aula e Scripts de Modelos Lineares (EST074)*. Departamento de Estatística, Universidade Federal de Juiz de Fora (UFJF), 2021-2025.